

SEMI-SUPERVISED CLASSIFICATION WITH GRAPH CONVOLUTIONAL NETWORKS

Thomas N. Kipf, Max Welling Presented in ICLR (2017)



HEART Lab 석사 과정생 고봉균, 유 건

2025. 7. 30

Contents



01. Introduction

02. Background

03. Experiments

1. Test 1


2. Test 2

04. Result

05. Conclusion


06. Example

- 한계점, 극복하기 위한 GNN




$$Z = f(X, A) = \text{softmax}\left(\hat{A} \text{ReLU}\left(\hat{A}XW^{(0)}\right)W^{(1)}\right).$$

2. Background



- Graph(그래프)는 ? ➔ $G = (V, E)$ 형태로 표현되는 집합
- V 는 **vertex**를 의미하고, node라고도 한다(정점)
- E 는 **edge**라고 하며, link라고도 한다(간선)

2. Background



그래프 예시 : Citeseer


- 노드(한 점) = Citeseer 데이터셋의 각 논문을 나타냄
- 엣지(연결선) = 한 논문이 다른 논문을 인용하는 관계 (방향성을 무시하여 무향 그래프 처리)



그래프 특징

- 연결이 많으면 중앙, 연결이 적으면 외곽으로 시각화하는 spring layout 알고리즘으로 Citeseer 시각화
- 각 노드 색깔은 6개 분야(Agent, AI, DB, IR, ML, HCI)가 고유 색상으로 매핑
- 중앙부 파랑, 보라, 노랑, 분홍이 뒤섞인 클러스터는 다양한 분야의 논문이 서로 인용하는 다학제 영역을 나타냄

2. Background



Adjacency Matrix(인접 행렬)

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

- 그래프에서 어떤 vertex(정점)끼리 연결되는지 표현
- 모든 vertex간의 relationship 정보를 담고 있는

Degree Matrix(차수 행렬)

$$D = \begin{pmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix}$$

- 노드의 차수(degree), 연결된 edge를 표현
- $\text{diag}(v)$ 형태 꼴로 표현, $\text{diag}(v)$ 는 벡터 v 를 대각으로 갖는 대각행렬

Graph Based Semi Supervised Learning

1. 그래프 라플라시안 정규화 방식

$$\mathcal{L} = \mathcal{L}_0 + \lambda f(X)^\top \Delta f(X)$$

- 노드 간 유사성을 유지하도록 손실 함수에 정규화 항 추가

2. 매니폴드 정규화 방식

$$\mathcal{L} = \mathcal{L}_0 + \lambda \mathcal{L}_{reg}, \text{ with } \mathcal{L}_{reg} = \sum_{i,j} A_{i,j} \|f(X_i) - f(X_j)\|^2$$

- 비라벨 데이터도 그래프 상에서 이웃 노드와 유사한 표현을 갖도록 학습함

기존의 Graph based Semi Supervised Learning은 손실함수에서 정규화항을 사용하는 반면 GCN은 모델 Layer에서 정규화항을 사용함, 따라서 레이어 깊이와 활성화 함수에 의해 비선형성을 갖고 표현력의 제한이 적음

2. Background

Graph Laplacian Matrix

$$L = D - A$$

$$D = \begin{pmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix}$$

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

$$L = \begin{pmatrix} 2 & -1 & -1 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 \\ -1 & -1 & 3 & 0 & -1 \\ 0 & -1 & 0 & 2 & -1 \\ 0 & 0 & -1 & -1 & 2 \end{pmatrix}$$

Normalized Graph Laplacian

$$\mathcal{L} = D^{-1}L$$

$$\mathcal{L} = \begin{pmatrix} 1 & -\frac{1}{2} & -\frac{1}{2} & 0 & 0 \\ -\frac{1}{3} & 1 & -\frac{1}{3} & -\frac{1}{3} & 0 \\ -\frac{1}{3} & -\frac{1}{3} & 1 & 0 & -\frac{1}{3} \\ 0 & -\frac{1}{2} & 0 & 1 & -\frac{1}{2} \\ 0 & 0 & -\frac{1}{2} & -\frac{1}{2} & 1 \end{pmatrix}$$

- Degree정보: 대각 원소, Adjacency 정보: 비대각 원소
- 대칭성을 가짐

- 노드 차수가 매우 달라지면 스케일이 노드마다 다름
→ 필터가 한쪽 노드에서 과대·과소 반응
- 행마다 자기 차수의 역수로 스케일링

2. Background

- Laplacian

$$\Delta f = \nabla^2 f = \nabla \cdot \nabla f$$

해당 포인트에서 아래로 볼록한지 ($\nabla^2 f > 0$) 또는 위로 볼록한지 ($\nabla^2 f < 0$)를 말해주는 것

Finite Difference Methods(FDM) 적용

$$\frac{d^2 f}{dx^2} \approx \frac{f(x+h) - f(x) + f(x-h) - f(x)}{h^2}$$

$$-\frac{2}{h^2} \left(f(x) - \frac{f(x+h) + f(x-h)}{2} \right)$$

중앙값 - 주변평균 꼴 형태

- 연산자 이산(discrete) Laplacian :
노드 i 의 값이 이웃 노드 평균과 얼마나 다른지

중앙값 - 주변평균 꼴 형태

$$(Lf)_i = d_i f_i - \sum_{j \in \mathcal{N}(i)} A_{ij} f_j$$

행렬 형태로 변환

$$L = D - A$$

2. Background

Symmetric Normalized Laplacian Matrix

$$L = D - A \quad \mathcal{L} = D^{-\frac{1}{2}} L D^{-\frac{1}{2}}$$

$$\begin{aligned} L_{sym} &= D^{-\frac{1}{2}} L D^{-\frac{1}{2}} = D^{-\frac{1}{2}} (D - A) D^{-\frac{1}{2}} \\ &= D^{-\frac{1}{2}} D D^{-\frac{1}{2}} - D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \\ &\Rightarrow L_{sym} = I - D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \end{aligned}$$

$$A_{sym} = \frac{A}{\sqrt{d_i d_j}}$$

- 행·열을 동시에 $\sqrt{\text{차수}}$ 로 보정 $\rightarrow$ 노드 차수의 차 동등
 - 대칭성을 가져 고유벡터 직교 $\rightarrow U^T U = I$, 고유분해 $U \Lambda U^T$
- $\rightarrow$ 그래프 푸리에 변환(GFT)·Chebyshev 근사에 이용



$$D = \begin{pmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix}$$

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

$$\mathcal{L}_{sym} = \begin{pmatrix} 1 & -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{6}} & 0 & 0 \\ -\frac{1}{\sqrt{6}} & 1 & -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{6}} & 0 \\ -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{6}} & 1 & 0 & -\frac{1}{\sqrt{6}} \\ 0 & -\frac{1}{\sqrt{6}} & 0 & 1 & -\frac{1}{\sqrt{6}} \\ 0 & 0 & -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{6}} & 1 \end{pmatrix}$$

$$L_{i,j}^{sym} := \begin{cases} 1 & \text{if } i = j \text{ and } \deg(v_i) \neq 0 \\ -\frac{1}{\sqrt{\deg(v_i) \deg(v_j)}} & \text{if } i \neq j \text{ and } v_i \text{ is adjacent to } v_j \\ 0 & \text{otherwise.} \end{cases}$$

2. Background



$$h_1^{(l+1)} = \sigma \left(\left(h_1^{(l)} + h_2^{(l)} + h_3^{(l)} + h_4^{(l)} \right) W^{(l)} + b^{(l)} \right), h_2^{(l+1)} = \sigma \left(\left(h_1^{(l)} + h_2^{(l)} \right) W^{(l)} + b^{(l)} \right),$$


각각의 노드를 기준으로 일일이 식을 나타냄 → 수식 표현 복잡성 증가, 데이터 증가로 인한 속도 감소

모든 노드(Vertex)들이 서로 연결되어 있다고 가정,

$$h_1^{(l+1)} = \sigma \left(\left(h_1^{(l)} + h_2^{(l)} + h_3^{(l)} + h_4^{(l)} \right) W^{(l)} + b^{(l)} \right), h_2^{(l+1)} = \sigma \left(\left(h_1^{(l)} + h_2^{(l)} + h_3^{(l)} + h_4^{(l)} \right) W^{(l)} + b^{(l)} \right), \dots$$

$$H^{(l+1)} = \sigma(H_1^{(l)} W^{(l)} + H_2^{(l)} W^{(l)} + H_3^{(l)} W^{(l)} + H_4^{(l)} W^{(l)} + b^{(l)})$$

2. Background



그래프 정보의 반영을 위한 Adjacency Matrix (A)를 곱,

$$H^{(l+1)} = \sigma(AH^{(l)}W^{(l)} + b^{(l)})$$

희소 인접행렬 $\tilde{A} = A + I_N$ 도입 $[-1,1]$

- 이웃 평균을 낼 때, 자기 정보의 손실 발생 가능성 제거
- 수치 안정화 : 1보다 크면 곱할수록 발산
- 고립 노드 문제 해결 : 간선 정보가 0 $\rightarrow$ 정규화 시 0으로 나누는 오류

Self-loop, Symmetric Normalized을 적용하여

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}\right)$$

2. Background

- 푸리에 변환 : 주어진 신호를 frequency domain 관점에서 요소의 합으로 분해
→ 그래프 노드 차를 주파수 분해하는 것의 관점으로 수식을 전개
- Graph Signal을 **Graph Laplacian Matrix**를 통해 새롭게 정의한 **eigen space**로 투사
→ 노드값 x 를 고유벡터 기준으로 '주파수 좌표'에 펼침.

Graph Fourier Transform

$$\tilde{x} = \sum_i u_i^T x$$

$$\therefore \tilde{x} = U^T x$$

Inverse GFT

$$x = U \tilde{x}$$

푸리에 합성곱 성질

$$\mathcal{F}\{\tilde{f} * \tilde{g}\} = \mathcal{F}\{\tilde{f}\} \cdot \mathcal{F}\{\tilde{g}\}$$

필터 $g(\Lambda)$ 합성곱

$$\text{conv}(x) = \text{IGFT}(\Lambda \cdot \tilde{x})$$

$$g(\Lambda)\tilde{x} = g(\Lambda)U^T x$$

$$y = U \tilde{y}$$

$$y = U g(\Lambda) U^T x$$

- U: 라플라시안 eigenvectors Matrix
- Λ : eigenvalue, $\Lambda = \text{diag}(\theta)$ 로 계산

2. Background

- 필터 $g(\Lambda)$ 합성곱 적용 $\rightarrow g_{\theta} * x = U g_{\theta}(\Lambda) U^T x$
- 전체 노드의 크기를 N 으로 두면, 행렬의 크기는 $N \times N \rightarrow U$ 계산 복잡도 $\mathcal{O}(N^2)$
- Eigendecomposition(고유분해) $U \Lambda U^T$ 값이 기하급수적으로 $\uparrow$ $y = U g(\Lambda) U^T x$

다항식으로 근사

$$g_{\theta}(\Lambda) \approx \sum_{k=0}^K \theta_k \Lambda^k$$

$\rightarrow$ 고유분해 없이 L 희소행렬
을 k 번 곱해 계산 가능.

Chebyshev polynomials(체비쇼프 다항식)

$$T_n(x) = \cos(ncos^{-1}(x)), for x \in [-1, 1]$$

- $T_0(x) = \cos(0) = 1$
- $T_1(x) = \cos(cos^{-1}(x)) = x$
- $T_2(x) = \cos(2cos^{-1}(x)) = 2x^2 - 1$
- $T_3(x) = \cos(3cos^{-1}(x)) = 4x^3 - 3x$
- 재귀적 성질 $T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x)$

계수 학습 안정적, 경계값에서의 수치 진동(over-shoot) 방지

Chebyshev polynomials 근사

- Chebyshev 다항식 근사 조건 : 입력 값이 $[-1,1]$ 구간

$$\tilde{\Lambda} = \frac{2}{\lambda_{max}} \Lambda - I_N$$

$$g_{\theta}(\Lambda) \approx \sum_{k=0}^K \theta_k \Lambda^k \longrightarrow g_{\theta'}(\Lambda) \approx \sum_{k=0}^K \theta'_k T_k(\tilde{\Lambda})$$

$$g_{\theta} * x = U g_{\theta}(\Lambda) U^T x \longrightarrow g_{\theta'} * x \approx U g_{\theta'}(\Lambda) U^T x \longrightarrow g_{\theta'} * x \approx \sum_{k=0}^K \theta'_k T_k(\tilde{L}) x$$

행렬다항식의 성질에 의거하여, $U g_{\theta'}(\Lambda) U^T = g_{\theta'}(U \Lambda U^T)$

$L = U \Lambda U^T$ 이므로, $g_{\theta'}(U \Lambda U^T) = g_{\theta'}(L)$

$$\tilde{L} = \frac{2}{\lambda_{max}} L - I_N$$

2. Background

K 는 근사하는 다항식의 차수

$$g_{\theta'} * x \approx \sum_{k=0}^K \theta'_k T_k(\tilde{L})x \xrightarrow[\tilde{L} = L - I_N]{K = 1, \lambda_{max} \approx 2} g_{\theta'} * x \approx \sum_{k=0}^1 \theta'_k T_k(\tilde{L})x, \quad g_{\theta'} * x \approx \theta'_0 T_0(\tilde{L})x + \theta'_1 T_1(\tilde{L})x$$

$$T_0(\tilde{L}) = 1, T_1(\tilde{L}) = \tilde{L}$$

$$g_{\theta'} * x \approx \theta'_0 x + \theta'_1 T_1(\tilde{L})x \xrightarrow{\quad} g_{\theta'} * x \approx \theta'_0 x + \theta'_1 (L - I_N)x, \quad L_{sym} = I - D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$$

$$g_{\theta'} * x \approx \theta'_0 x + \theta'_1 (L - I_N)x = \underbrace{\theta'_0 x}_{\text{자기정보}} - \underbrace{\theta'_1 D^{-\frac{1}{2}} A D^{-\frac{1}{2}} x}_{\text{이웃정보}}$$

$$\theta = \theta'_0 = -\theta'_1$$

자기정보 이웃정보

2. Background

$$g_{\theta} \star x \approx \theta \left(\underbrace{I_N + D^{-\frac{1}{2}} A D^{-\frac{1}{2}}}_{\tilde{A}} \right) x$$

$$\tilde{A} = A + I_N, \quad \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$

Renormalization trick

$$Z = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X \Theta$$

- Z : 도출되는 feature map
- X : 입력 채널 C 와 노드 수 N 의 행렬
- Θ : 입력 채널 C 와 필터 수 F 의 행렬

논문 수식 : 1-hidden layer GCN

$$\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$




$$Z = f(X, A) = \text{softmax} \left(\hat{A} \text{ReLU} \left(\hat{A} X W^{(0)} \right) W^{(1)} \right)$$

- 인접행렬 A 만 쓰면 각 노드가 이웃 수가 많은 경우 정보 과다, 적은 경우 너무 적게 들어옴 → **편향 발생**
- 이웃의 수에 따른 정보량 차이로 인한 **학습 불안정**
- $W^{(0)}$: 입력 - 은닉층 가중치 행렬($C \times H$)
- $W^{(1)}$: 은닉층 - 출력 가중치 행렬($H \times F$)

3. Semi-Supervised Node Classification

Model Architecture



입력층
각 노드의 초기 특성(feature)
벡터 집합, 그래프 연결 구조
(인접 행렬)

합성곱 층
인접 노드 특성 $\hat{A}$ 을 구조 행렬
로 집계하고 가중치 θ 를 통해
새로운 노드 표현 생성

출력층
Softmax 함수를 통해 예측된
각 노드의 라벨

3. Semi-Supervised Node Classification

Model Architecture


$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \dots (2) \quad \text{Hidden State}$$

$$\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} \quad \text{라플라시안 정규화 항}$$

$$\theta = W^{(l)} \quad \text{손실함수를 통해 학습가능한 파라미터}$$

$$Z = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X \theta = \hat{A} X \theta \quad \text{은닉 계층}$$

$$Z = f(X, A) = \text{softmax}(\hat{A} \cdot \text{ReLU}(\hat{A} X W^0) W^1) \quad \text{2-layer GCN}$$




핵심 포인트

- 입력 : X = 노드 특징, A = 그래프 인접행렬
- 출력 : 노드 별 클래스 확률
- 라벨은 일부 노드(X)에만 존재함

모델 구조 = 두개의 계층

- 첫번째 계층 : 이웃 특징 집계 + ReLU
- 두번째 계층 : 이웃 특징 집계 + softmax



3. Semi-Supervised Node Classification

Model Architecture

1. 라벨이 있는 경우의 데이터 학습

$$L = - \sum_{l \in Y_L} \sum_{f=1}^F Y_{lf} \ln Z_{lf}$$

- 라벨이 있는 노드의 경우 다음 손실 함수로 학습한다.
- Y_L = 라벨이 있는 노드 인덱스 집합

2. 라벨이 없는 경우 비지도 데이터 분류

$$Z = \text{softmax}(\hat{A} \cdot \text{ReLU}(\hat{A}XW^0)W^1)$$


$$\hat{y}_i = \arg \max_f \hat{Z}_{if}$$

- 손실함수를 통해 학습한 신경망 Z에 대해 그래프 구조 $\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ 를 통해 모든 비라벨링 된 노드 $\hat{y}_i$ 를 forward 한다
- 비라벨 노드도 $\hat{A}$ 연산에 참여하므로 손실 함수 학습 과정에서 기여함

4. Experiments

Experiment Environments – Citeseer, Cora, Pubmed


Cora
Nodes=2708, Edges=10556, Features=1433, Classes=7



Cora

- Andrew McCallum 팀의 검색 엔진을 통한 인터넷 PDF 논문 크롤링
- 7개의 클래스, 2708개의 노드 중 5%만 라벨링
- 논문간 인용 관계 제목, 초록, 본문에서 추출한 Bag-of-Words(BW) 특징 포함


Citeseer
Nodes=3327, Edges=9104, Features=3703, Classes=6



Citeseer

- NEC Research Institute가 운영하던 Citeseer Digital Library를 통한 PDF문서, 인용정보 수집
- 6개의 클래스, 3227개의 노드 중 3.6%만 라벨링
- 논문 간 인용 네트워크, BoW 특징 포함 및 전처리 후 중복, 불완전 논문 제거

Pubmed
Nodes=19717, Edges=88648, Features=500, Classes=3




Pubmed

- 미국 국립생물공학정보센터의 바이오메디컬 논문 데이터베이스 중 당뇨병 관련 의학 논문
- 3개의 클래스(의학 주제어 기반 분류), 19717개의 노드 중 0.3%만 라벨링
- 제목, 초록 단어로 BoW 특징 생성


4. Experiments

Experiment Environments – Citeseer, Cora, Pubmed


Cora — Connected 10 nodes
 $|V|=10, |E|=18$



Citeseer — Connected 10 nodes
 $|V|=10, |E|=11$




Pubmed — Connected 10 nodes
 $|V|=10, |E|=19$



- 각각의 노드는 제목, 초록, 본문 등에서 만든 Bag-of-Words 특징으로 표현됩니다.
- 간선은 무향이며 인용 관계를 나타냅니다. 인용, 피인용 방향성은 Plaintod 벤치마크 특성상 인접행렬을 대칭화해서 사용하므로 반영되지 않습니다.

4. Experiments

Experiment Environments – NELL Dataset



- 각각의 노드는 엔티티(개념)를 의미하며 클래스는 사람, 국가, 도시, 조직, 스포츠팀 등으로 나타냅니다.
- 각각의 간선은 방향성을 갖고 있으며 간선의 속성 또한 존재합니다.

4. Experiments

Experiment Environments

Dataset	Type	Nodes	Edges	Classes	Features	Label rate
Citeseer	Citation network	3,327	4,732	6	3,703	0.036
Cora	Citation network	2,708	5,429	7	1,433	0.052
Pubmed	Citation network	19,717	44,338	3	500	0.003
NELL	Knowledge graph	65,755	266,144	210	5,414	0.001

Citation networks

- 클래스 당 20개의 데이터셋으로 학습
- Valid 개수 = 500
- Test 개수 = 1000개
- Citeseer, Cora : 컴퓨터 분야, Pubmed = 의학 논문 분야

Knowledge graph

- 클래스 당 1개의 데이터로 학습
- Valid 개수 = 500
- Test 개수 = 1000개

- Feature는 노드를 특징 벡터로 임베딩 할 때 BoW (Bag-of-Words) 기반으로 특징을 추출하는데 단어 빈도수를 추출하는데 사용되는 단어의 개수이다.

Table 2: Summary of results in terms of classification accuracy (in percent).

Method	Citeseer	Cora	Pubmed	NELL
ManiReg [3]	60.1	59.5	70.7	21.8
SemiEmb [28]	59.6	59.0	71.1	26.7
LP [32]	45.3	68.0	63.0	26.5
DeepWalk [22]	43.2	67.2	65.3	58.1
ICA [18]	69.1	75.1	73.9	23.1
Planetoid* [29]	64.7 (26s)	75.7 (13s)	77.2 (25s)	61.9 (185s)
GCN (this paper)	70.3 (7s)	81.5 (4s)	79.0 (38s)	66.0 (48s)
GCN (rand. splits)	67.9 $\pm$ 0.5	80.1 $\pm$ 0.5	78.9 $\pm$ 0.7	58.4 $\pm$ 1.7


GCN (rand. Splits) = 같은 2-layer GCN 모델이지만 데이터셋의 학습/검증/테스트 셋을 무작위로 재분할함, 다만 라벨 수나 분포가 불리할 수 있음

Table 2: Summary of results in terms of classification accuracy (in percent).

Method	Citeseer	Cora	Pubmed	NELL
ManiReg [3]	60.1	59.5	70.7	21.8
SemiEmb [28]	59.6	59.0	71.1	26.7
LP [32]	45.3	68.0	63.0	26.5
DeepWalk [22]	43.2	67.2	65.3	58.1
ICA [18]	69.1	75.1	73.9	23.1
Planetoid* [29]	64.7 (26s)	75.7 (13s)	77.2 (25s)	61.9 (185s)
GCN (this paper)	70.3 (7s)	81.5 (4s)	79.0 (38s)	66.0 (48s)
GCN (rand. splits)	67.9 $\pm$ 0.5	80.1 $\pm$ 0.5	78.9 $\pm$ 0.7	58.4 $\pm$ 1.7

- 모델 정규화 $\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ 채택으로 그래프 구조와 노드 특징을 동시에 처리하여 DeepWalk, Planetoid 보다 높은 성능 달성
- 따라서 단순 2-layer 구조로도 기존 모든 모델보다 효율성, 정확도 상회함

5. Results



- GCN은 메시지 패싱 구조여서 층이 늘어날 수록 더 넓은 범위의 이웃 정보가 통합됨
- 따라서 너무 많은 이웃 정보가 섞이기 때문에 노드 간 특징 벡터의 구분이 어려워지고 분류 경계가 모호해짐 (Over smoothing)
- Residual Structure를 도입하여 일부 성능 하락을 완화시켰으나 2 – Layer GCN이 최고성능을 보임

1. 그래프 구조 데이터 반지도 학습을 위한 새로운 신경망 Graph Convolution Network 제안
2. GCN은 Spectral Graph Convolution을 1차 근사하여 효율적인 계층별 전파구조 보유
3. 기존의 손실함수 정규화 항을 모델 구조 안에서 구현($\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$)하여 모델 자체가 비라벨된 노드에 대한 정보를 전파합니다
4. 위와 같은 구조로 기존 방법들보다 학습 속도와 정확도 모두 우수한 성능을 보이며 새로운 강력한 기준이 될 수 있었다.

감사합니다

