

Bootstrap Your Own Latent

A New Approach to Self-Supervised Learning

Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, Michal Valko Presenting in NIPS (2020)

HEART Lab 석사 과정 고봉균, 학부 인턴 과정 유 건

2025. 7. 30

Contents



01. Introduction

02. Background


03. Method

04. Experiments


05. Results

06. Conclusion

1. Introduction



Contrastive Learning




BYOL

- Positive pair: 같은 이미지의 서로 다른 증강 뷰 → 가깝게 학습
- Negative pair: 다른 이미지의 증강 뷰 → 멀게 학습
- 목적: 표현 공간에서 유사한 것은 가깝게, 다른 것은 멀게 배치하여 구분 가능한 특징 표현 학습
- Negative pair 없이 positive pair만 사용 → 같은 이미지의 두 개 다른 증강 뷰 (two views)를 사용
- Self-supervised learning 방식


2. Background

What is Self-Supervised?




- Supervision을 위한 대량의 labelled data 특히 high-quality의 labelled data를 얻는 것은 비용 ↑
- unlabeled dataset으로부터 좋은 representation을 얻고자 하는 학습방식
→ 다양한 downstream task에 빠르게 적응
- label(y) 없이 input(x) 내에서 target을 정해서 self로 task를 정해서 supervision 방식 학습

DeepCluster




- 이전 단계 표현으로 다음 단계의 학습 목표(라벨) 생성
- k-means로 임베딩을 K개의 클러스터로 묶고, 각 이미지의 클러스터 ID를 가짜 라벨로 삼아 CNN을 손실함수 cross-entropy로 사용하여 학습
- 주기적으로 임베딩 추출 + 대규모 k-means의 계산/메모리 비용, 클러스터 붕괴/편향 · 의미적 불변성 학습이 약함

Contrastive Learning



- 유사한 sample pair들은 거리가 가깝게 그리고 유사하지 않은 sample pair의 거리는 멀게 학습
- 큰 Batch Size를 사용하여 최대한 많은 Sample 을 하나의 Batch 에 포함시켜 일관된 학습 방향 유도 → batch size, epoch의 증가는 연산비용 ↑
- representation collapse를 해결하기 위해 많은 negative sample이 필요

Self-Supervised - MOCO




(b) Momentum Contrast

Memory Bank : 아주 많은 샘플을 저장해놓고 비교하면서 학습
Sampling을 할 때마다 밀어내야 하는 방향이 바뀐다는 단점
→ 키 인코더가 매 스텝 바뀌면, 분포가 달라져 학습이 흔들림

MOCO : Encoder는 기존과 동일하게 Contrastive Loss로 바로바로 업데이트, Momentum을 사용한 인코더는 천천히 업데이트
과거와 현재 이미지의 분포가 일관됨

3. Method




많은 Negative Sample 없이 Self Supervised Learning 방식으로 학습

동일한 이미지로 부터 다른 관점을 예측하는 것, 하나의 원본 이미지 x 에 서로 다른 증강을 적용

지수 이동 평균을 적용한 parameter ξ 추가

3. Method



online networks:


- online parameter θ
- encoder f_θ , projector g_θ , predictor q_θ
→ 각 MLP와 head로 구성
- Backpropagation을 online network만 적용

target networks:

- 가중치 parameter ξ - θ 의 지수 이동 평균
- encoder f_ξ , projector g_ξ
→ 각 MLP와 head로 구성
- 파라미터 업데이트 $\xi \leftarrow \tau\xi + (1 - \tau)\theta$

3. Method

Projection head, Prediction head



Head : 출력 크기 (입력 $\rightarrow$ 4096) $\rightarrow$ 배치정규화 $\rightarrow$ ReLU 함수 $\rightarrow$ (4096 $\rightarrow$ 256) 적용 2-layer MLP 레이어

online networks:

- encoder $f_\theta : y_\theta = f_\theta(v)$
- projector $g_\theta : z_\theta = g_\theta(y_\theta)$
- predictor $q_\theta : \hat{z}_\theta = q_\theta(y_\theta)$

target networks:


- encoder $f_\xi : y'_\xi = f_\xi(v')$
- projector $g_\xi : z'_\xi = g_\xi(y'_\xi)$

- BYOL은 negative sample이나 붕괴 방지 항 없이 θ 만 최소화, undesirable equilibrium 도 존재 가능
모든 z 가 같은 상수벡터 c 이고, predictor q_θ 가 $c \mapsto c$ 가 되면 손실이 아주 작아지는 평형 발생
→ BYOL's predictor의 최적조건 가정: $q_\theta = q^*$
- $q^*(z_\theta) = \mathbb{E}[z'_\xi | z_\theta]$, $q^* = \arg \min_q \mathbb{E}[\|q_\theta(z_\theta) - z'_\xi\|_2^2]$
→ 온라인 투영 z_θ 가 주어졌을 때 타깃 투영 z'_ξ 의 조건부 평균 예측
- θ update시, $\nabla_\theta \mathbb{E}[\|q^*(z_\theta) - z'_\xi\|_2^2] = \nabla_\theta \mathbb{E}[\|\mathbb{E}[z'_\xi | z_\theta] - z'_\xi\|_2^2] = \nabla_\theta \mathbb{E}[\sum_i \text{Var}(z'_\xi | z_\theta)]$
→ 온라인 투영 z_θ 가 타깃 투영 z'_ξ 의 불확실성을 줄여 더 예측 가능하게 만드는 특징 학습

- l_2 정규화 기법 적용 : $\bar{q}_\theta(z_\theta) = \frac{q_\theta(z_\theta)}{\|q_\theta(z_\theta)\|_2}$, $\bar{z}'_\xi = \frac{z'_\xi}{\|z'_\xi\|_2}$
→ 온라인의 예측 $\bar{q}_\theta(z_\theta)$ 가 타겟의 표현 $\bar{z}'_\xi$ 와 같아지도록(가깝도록) 학습.
- 손실함수 : $L_{\theta,\xi} = \|\bar{q}_\theta(z_\theta) - \bar{z}'_\xi\|_2^2 = \|\bar{q}_\theta(z_\theta)\|_2^2 + \|\bar{z}'_\xi\|_2^2 - 2 \bar{q}_\theta \cdot \bar{z}'_\xi \rightarrow L_{\theta,\xi} = 2 - 2 \frac{\langle q_\theta(z_\theta), z'_\xi \rangle}{\|q_\theta(z_\theta)\|_2 \cdot \|z'_\xi\|_2}$
- $minimize L_{\theta,\xi}^{BYOL} = L_{\theta,\xi} + \tilde{L}_{\theta,\xi}$ (양방향 평균) , $\theta \leftarrow optimizer(\theta, \nabla_\theta, L_{\theta,\xi}^{BYOL}, \eta)$
* η : Learning rate.
- ξ 는 역전파 과정에 참여하지 않고, $\xi \leftarrow \tau \xi + (1 - \tau) \theta$ 으로 파라미터 update ($\tau \approx 0.99 \sim 0.996$)
손실 기울기로 업데이트가 아닌 지수이동평균으로 θ 를 따라감 온라인이 방금 학습한 정보를 천천히 반영

$$\xi_t = (1-\tau) \sum_{k=0}^t \tau^{t-k} \theta_k$$


3. Method




- BYOL은 같은 이미지에서 만든 두 개의 증강 뷰를 넣고, 두 뷰의 표현(representation)간 거리 즉, 온라인 예측 $q_\theta(z_\theta)$ 와 타깃 표현 z'_ξ 의 코사인 거리를 줄이도록 학습 → 더 예측 가능하게 만드는 특징 학습
- EMA로 느리게 업데이트 되는 Target에 online이 맞춰서 학습하는 구조이고, 이미지 증강으로 인하여, 두 뷰는 색/자르기/노이즈의 차이 발생. 두 증강의 차이를 줄이려면 → 공통적인 의미 및 구조 특징(불변 표현)을 학습

3. Method

Image Augmentations




jittering : 밝기, 대비, saturation(채도) 균일분포 샘플링



가우시안 blurring : Gaussian kernel 23 x 23




solarization(솔라리제이션)



224x 224 resize crop

Model Architecture

Global-average 적용



$z, \bar{z}'_\xi$ 는 Head를 통과하여 출력 256-D 벡터

LARS optimizer(Layer-wise Adaptive Rate Scaling)

- 계산식 : 레이어 비율 $r_l = \eta \cdot \frac{\|w_l\|}{\|g_l\| + \lambda\|w_l\| + \varepsilon}$ η : layer-wise scaling 계수(보통 0.001~0.02)

$$p_l = g_l + \lambda w_l$$

λ : weight decay(l_2)

ε : 0으로 나눔 방지용 작은 값

- Update $v_l \leftarrow \mu v_l + r_l \cdot p_l$, $w_l \leftarrow w_l - \gamma \cdot v_l$

전역 학습률 γ 는 공통으로 쓰고, 레이어마다 η_l 을 곱해 로컬 보폭을 만듦

→ 가중치 크기에 비해 gradient가 지나치게 작은 레이어도 충분히 움직이고, 너무 큰 레이어는 과도하게 움직이지 않게

- $Learning\ Rate = 0.2 \cdot \frac{BatchSize}{256}$

- Cosine scheduler : $\tau_k = base \frac{\cos(\pi \frac{k}{K}) + 1}{2}$, k 는 현재 학습 스텝, K 는 전체 스텝 수

- 초기 학습으로 생기는 변동을 타깃으로 빠르게 옮겨야 두 뷰 일관성이 잘 학습, 후반부 안정화를 통해 붕괴 방지와 BYOL 가정을 유지

4. Experiment

4.1 Experiment Environments – Linear Evaluation on ImageNet

Method	Top-1	Top-5
Local Agg.	60.2	-
PIRL [35]	63.6	-
CPC v2 [32]	63.8	85.3
CMC [11]	66.2	87.0
SimCLR [8]	69.3	89.0
MoCo v2 [37]	71.1	-
InfoMin Aug. [12]	73.0	91.1
BYOL (ours)	74.3	91.6

(a) ResNet-50 encoder.

Method	Architecture	Param.	Top-1	Top-5
SimCLR [8]	ResNet-50 (2×)	94M	74.2	92.0
CMC [11]	ResNet-50 (2×)	94M	70.6	89.7
BYOL (ours)	ResNet-50 (2×)	94M	77.4	93.6
CPC v2 [32]	ResNet-161	305M	71.5	90.1
MoCo [9]	ResNet-50 (4×)	375M	68.6	-
SimCLR [8]	ResNet-50 (4×)	375M	76.5	93.2
BYOL (ours)	ResNet-50 (4×)	375M	78.6	94.2
BYOL (ours)	ResNet-200 (2×)	250M	79.6	94.8

(b) Other ResNet encoder architectures.

Table 1: Top-1 and top-5 accuracies (in %) under linear evaluation on ImageNet.

- 각각 위의 표 방식대로 사전학습 후 Downstream task
- Downstream task = 2048-1000차원 FCL+ softmax, optimizer : SGD + Nesterov momentum
- (b) 인코더 구조 – ResNet50 * 4 : ResNet50 Architecture의 Conv channel 수 4배
- ResNet200 * 2 : ResNet200 Architecture의 Conv channel 수 2배

4. Experiment

4.1 Experiment Environments – Linear Evaluation on ImageNet

학습 방법	사전학습 방식	BYOL과 차이
Local Aggregation	Feature space에서 k-NN으로 Local Neighbor를 찾고, 이웃끼리 positive, 이웃 외에는 negative	BYOL은 neighbor 없이 같은 이미지의 다른 view만을 사용, negative 없이 predictor + EMA로 collapse 방지
PIRL/CMC/CPC v2	각각의 pretext task, multi view, contrastive loss 활용	BYOL은 pretext 없이 representation bootstrap
SimCLR	Contrastive Learning, Positive,negative pair 비교, projection head 사용	BYOL은 negative pair 없이 학습
MoCo v2	Momentum encode로 메모리 बैं크 유지, contrastive loss	BYOL은 momentum encoder를 target network로 쓰지만 negative 없음
InfoMin Aug	Contrastive + 다양한 증강 최적화	BYOL은 증강에 덜 민감

4.2 Experiment Environments – semi-supervised training on ImageNet

Method	Top-1		Top-5	
	1%	10%	1%	10%
Supervised [77]	25.4	56.4	48.4	80.4
InstDisc	-	-	39.2	77.4
PIRL [35]	-	-	57.2	83.8
SimCLR [8]	48.3	65.6	75.5	87.8
BYOL (ours)	53.2	68.8	78.4	89.0

(a) ResNet-50 encoder.

Method	Architecture	Param.	Top-1		Top-5	
			1%	10%	1%	10%
CPC v2 [32]	ResNet-161	305M	-	-	77.9	91.2
SimCLR [8]	ResNet-50 (2×)	94M	58.5	71.7	83.0	91.2
BYOL (ours)	ResNet-50 (2×)	94M	62.2	73.5	84.1	91.7
SimCLR [8]	ResNet-50 (4×)	375M	63.0	74.4	85.8	92.6
BYOL (ours)	ResNet-50 (4×)	375M	69.1	75.7	87.9	92.5
BYOL (ours)	ResNet-200 (2×)	250M	71.2	77.7	89.5	93.7

(b) Other ResNet encoder architectures.

Table 2: Semi-supervised training with a fraction of ImageNet labels.

- Downstream Task = 2048-1000 차원 FCL + softmax Imagenet 중 1% or 10%만 라벨 존재
- 라벨이 있는 소량의 ImageNet 데이터로 전체 네트워크 파라미터를 미세 조정
- 사전 학습 단계에선 라벨 없는 데이터만 사용함

4. Experiment

4.3 Experiment Environments – Transfer to other classification tasks

Method	Food101	CIFAR10	CIFAR100	Birdsnap	SUN397	Cars	Aircraft	VOC2007	DTD	Pets	Caltech-101	Flowers
<i>Linear evaluation:</i>												
BYOL (ours)	75.3	91.3	78.4	57.2	62.2	67.8	60.6	82.5	75.5	90.4	94.2	96.1
SimCLR (repro)	72.8	90.5	74.4	42.4	60.6	49.3	49.8	81.4	75.7	84.6	89.3	92.6
SimCLR [8]	68.4	90.6	71.6	37.4	58.8	50.3	50.3	80.5	74.5	83.6	90.3	91.2
Supervised-IN [8]	72.3	93.6	78.3	53.7	61.9	66.7	61.0	82.8	74.9	91.5	94.5	94.7
<i>Fine-tuned:</i>												
BYOL (ours)	88.5	97.8	86.1	76.3	63.7	91.6	88.1	85.4	76.2	91.7	93.8	97.0
SimCLR (repro)	87.5	97.4	85.3	75.0	63.9	91.4	87.6	84.5	75.4	89.4	91.7	96.6
SimCLR [8]	88.2	97.7	85.9	75.9	63.5	91.3	88.1	84.1	73.2	89.2	92.1	97.0
Supervised-IN [8]	88.3	97.5	86.4	75.8	64.3	92.1	86.0	85.0	74.6	92.1	93.3	97.6
Random init [8]	86.9	95.9	80.2	76.1	53.6	91.4	85.9	67.3	64.8	81.5	72.6	92.0

Table 3: Transfer learning results from ImageNet (IN) with the standard ResNet-50 architecture.

- ImageNet 이외의 다른 데이터에서 다운스트림 테스트를 통해 top-1 acc 측정
- 12개 데이터셋 중 linear eval 시 5개 sota, Fine-tuning 시 7개 sota
- Cifar : 숫자 손글씨, SUN397 : 장면 인식, DTD : 텍스처 인식, VOC : 객체 인식, Caltech : 객체 분류

4. Experiment

4.3 Experiment Environments – Transfer to other classification tasks

Method	Food101	CIFAR10	CIFAR100	Birdsnap	SUN397	Cars	Aircraft	VOC2007	DTD	Pets	Caltech-101	Flowers
<i>Linear evaluation:</i>												
BYOL (ours)	75.3	91.3	78.4	57.2	62.2	67.8	60.6	82.5	75.5	90.4	94.2	96.1
SimCLR (repro)	72.8	90.5	74.4	42.4	60.6	49.3	49.8	81.4	75.7	84.6	89.3	92.6
SimCLR [8]	68.4	90.6	71.6	37.4	58.8	50.3	50.3	80.5	74.5	83.6	90.3	91.2
Supervised-IN [8]	72.3	93.6	78.3	53.7	61.9	66.7	61.0	82.8	74.9	91.5	94.5	94.7
<i>Fine-tuned:</i>												
BYOL (ours)	88.5	97.8	86.1	76.3	63.7	91.6	88.1	85.4	76.2	91.7	93.8	97.0
SimCLR (repro)	87.5	97.4	85.3	75.0	63.9	91.4	87.6	84.5	75.4	89.4	91.7	96.6
SimCLR [8]	88.2	97.7	85.9	75.9	63.5	91.3	88.1	84.1	73.2	89.2	92.1	97.0
Supervised-IN [8]	88.3	97.5	86.4	75.8	64.3	92.1	86.0	85.0	74.6	92.1	93.3	97.6
Random init [8]	86.9	95.9	80.2	76.1	53.6	91.4	85.9	67.3	64.8	81.5	72.6	92.0

Table 3: Transfer learning results from ImageNet (IN) with the standard ResNet-50 architecture.

- Upstream task: ImageNet 전체를 라벨 없이 BYOL로 학습해서 ResNet50 feature 추출
- Downstream task –linear eval : 인코더 가중치 고정 + 선형 분류기만 학습
-Fine-tune : 인코더 + 선형 분류기 까지 전부 업데이트

4. Experiment

4.4 Experiment Environments – Transfer to other vision tasks

Method	AP ₅₀	mIoU
Supervised-IN [9]	74.4	74.4
MoCo [9]	74.9	72.5
SimCLR (repro)	75.2	75.2
BYOL (ours)	77.5	76.3

(a) Transfer results in semantic segmentation and object detection.

Method	pct.< 1.25	Higher better pct.< 1.25 ²	pct.< 1.25 ³	Lower better rms	Lower better rel
Supervised-IN [83]	81.1	95.3	98.8	0.573	0.127
SimCLR (repro)	83.3	96.5	99.1	0.557	0.134
BYOL (ours)	84.6	96.7	99.1	0.541	0.129

(b) Transfer results on NYU v2 depth estimation.

Table 4: Results on transferring BYOL's representation to other vision tasks.

- Upstream task : 라벨 없는 ImageNet Self-Supervised-Learning
- Downstream task : Object detection, Depth estimation, Semantic segmentation
- AP50 : Object Detection, mIoU : Semantic Segmentation, AbsRel : Depth Estimation

4. Experiment

4.4 Experiment Environments – Transfer to other vision tasks

지표	수식	주 사용 분야	의미/직관
AP50	$\int_0^1 p(r)dr$	Object Detection	예측 박스가 정답과 50% 이상 겹쳤을 때 정밀, 재현 성능 요약
IoU	$\frac{ P \cap G }{ P \cup G }$	Semantic Segmentation	예측과 정답의 합집합 대비 교집합 비율
mIoU	$\frac{1}{C} \sum_c \frac{ P_c \cap G_c }{ P_c \cup G_c }$	Semantic Segmentation	클래스 별 IoU의 평균(적합도)
σ -accuracy ($\sigma < 1.25^n$)	$i : \max(\frac{d_i}{d_i^*}, \frac{d_i^*}{d_i}) < 1.25^n$	Depth Accuracy	허용오차 상한 : 예측이 실제의 25%, 56%, 95% 내외일 확률
RMSE	$\sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - d_i^*)^2}$	Depth Accuracy	깊이 차이값의 절댓값 평균
AbsRel	$\frac{1}{N} \sum_{i=1}^N \frac{ d_i - d_i^* }{d_i^*}$	Depth Accuracy	깊이 차이 비율의 평균


4.4 Experiment Environments – Transfer to other vision tasks



- RGB 한장에서 픽셀별 거리맵을 회귀하는 과제
- 입출력 : 입력 이미지 -> 출력 $H \times W$ 연속 스칼라 맵
- 평가지표 : AbsRel, RMSE, $\sigma < 1.25^n$
- ResNet-50 Backbone + 4-Layer fast up-projection (512/256/128/64) $\rightarrow$ berHu Loss

입력(좌)과 Depth map(우) : 가까운 보행자/차량은 밝고, 멀리있는 건물/하늘은 어둡게 표현

4.4 Experiment Environments – Transfer to other vision tasks



도로 장면에서 차량/버스에 바운딩 박스와 라벨이 붙은 예시

- 이미지 속 객체의 위치(박스)와 클래스를 함께 예측
- 입·출력: $(x,y,w,h,c,s) \rightarrow (x,y = \text{박스 위치}), (w,h = \text{박스의 너비, 높이}), (c,s = \text{클래스, 신뢰도 점수})$
- 평가지표 : AP50(IoU 0.5에서의 평균정밀도)
- Faster R-CNN (R50-C4), 백본 동결(frozen), 멀티스케일 리사이즈(긴 변 480–1024)

CNN에서 병목 현상을 줄이기 위해 고안, Feature map으로 부터 Selective search 알고리즘을 수행하여 Region Proposal을 생성하여 물체 후보군 선정

4. Experiment

4.4 Experiment Environments – Transfer to other vision tasks



차로·보도·차량·표지판을 색으로 구분한 분할 결과


- 픽셀마다 클래스 라벨을 붙여 마스크를 만드는 밀집 분류
- 입·출력: $H \times W \times K$ 확률 맵 $\rightarrow$ 클래스별 컬러 마스크
- 평가지표: mIoU(클래스별 IoU 평균)
- FCN-16s(ResNet-50 백본, conv5 dilation=2), VOC2012 end-to-end 미세조정

FCN : 이미지 분류에서 우수한 성능을 보인 CNN 기반 모델(AlexNet, VGG16, GoogLeNet)을 Semantic Segmentation Task를 수행할 수 있도록 변형시킨 모델

4. Experiment


4.4 Experiment Environments – Transfer to other vision tasks / Model

Faster R-CNN



- 물체가 속할 수 있는 후보군을 제안하는 **Region Proposal**
- **cls-layer** : object score, **reg-layer**: object proposal을 출력
- 9개의 고정된 크기로 된 Anchor box(bounding-box)를 생성하고, 최적의 anchor box를 찾기 위해 가장 높은 확률값만 남김

FCN




- Fully-connected 레이어를 1x1 convolution 레이어로 변경
- **Transposed Convolution** : input 보다 output의 공간적 차원이 더 큰 업-샘플링 사용
- **Skip architecture** : 피쳐 추출 단계의 피쳐맵도 업-샘플링에 포함(Sum)하여 위치 정보 손실 방지

5. Building intuitions with ablations

5.1 Batch size

- Upstream task로 BYOL, SimCLR 두 기법에 대해 배치크기 4096부터 128까지 축소
- 배치 사이즈마다 기준 사이즈 (4096) 대비 top-1 정확도 하락폭 표시
- 배치 사이즈를 줄여도 Back Propagation 업데이트 수는 기준 사이즈와 동일하게 진행
- BYOL은 배치사이즈를 조정하여도 SimCLR 보다 덜 민감한 추세를 보임




(a) Impact of batch size

5. Building intuitions with ablations

5.2 Image augmentation

- Upstream task로 BYOL, SimCLR 두 기법에 대해 증강을 하나씩 제거하여 특정 증강에 대한 학습 민감도 파악
- 비대칭 증강을 포함한 강, 약 혼합 파이프라인 상 색상/블러/플립을 순차적으로 제거하며 최종적으로 증강을 Crop만 사용하는 단계까지 진행했을 때 기존 대비 ACC 하락 추세
- BYOL은 증강에 덜 민감하고 색상 변형 제거나 극단 축소에서도 상대적으로 성능 유지가 잘 됨



(b) Impact of progressively removing transformations

5. Building intuitions with ablations

5.3 Boot straping (a)

Target	τ_{base}	Top-1
Constant random network	1	18.8 ± 0.7
Moving average of online	0.999	69.8
Moving average of online	0.99	72.5
Moving average of online	0.9	68.4
Stop gradient of online [†]	0	0.3

(a) Results for different target modes. [†]In the *stop gradient of online*, $\tau = \tau_{\text{base}} = 0$ is kept constant throughout training.

Method	Predictor	Target network	β	Top-1
BYOL	✓	✓	0	72.5
—	✓	✓	1	70.9
—		✓	1	70.7
SimCLR			1	69.4
—	✓		1	69.1
—	✓		0	0.3
—		✓	0	0.2
—			0	0.1

(b) Intermediate variants between BYOL and SimCLR.

Table 5: Ablations with top-1 accuracy (in %) at 300 epochs under linear evaluation on ImageNet.

- A에서 τ_{base} 는 타겟 네트워크의 EMA 계수 $\tau = 1$ 일 때는 타겟 네트워크 업데이트 X
- 온라인을 통한 EMA 업데이트 계수 $\tau = 0.99$ 일 때 Accuracy 가장 높음
- $\tau = 0$ 일때는 타겟 네트워크 = 온라인 네트워크 이므로 모델 collapse

5. Building intuitions with ablations

5.3 Boot straping (b)

Target	τ_{base}	Top-1
Constant random network	1	18.8 ± 0.7
Moving average of online	0.999	69.8
Moving average of online	0.99	72.5
Moving average of online	0.9	68.4
Stop gradient of online [†]	0	0.3

(a) Results for different target modes. [†]In the *stop gradient of online*, $\tau = \tau_{\text{base}} = 0$ is kept constant throughout training.

Method	Predictor	Target network	β	Top-1
BYOL	✓	✓	0	72.5
—	✓	✓	1	70.9
—		✓	1	70.7
SimCLR			1	69.4
—	✓		1	69.1
—	✓		0	0.3
—		✓	0	0.2
—			0	0.1

(b) Intermediate variants between BYOL and SimCLR.

Table 5: Ablations with top-1 accuracy (in %) at 300 epochs under linear evaluation on ImageNet.

- $\beta = 1$ 일때는 negative 항끼리 멀어지는 경우, $\beta = 0$ 일 때는 negative 없이 positive 만을 통한 학습
- BYOL에 negative repulsion 도입 시 ($\beta = 1$) 성능 소폭 하락
- SimCLR에 각각 predictor, Target Network 도입 시 성능 극단적으로 하락

5. Building intuitions with ablations

5.4 Ablation with Contrastive methods

$$\text{InfoNCE}_{\theta}^{\alpha, \beta} \triangleq \frac{2}{B} \sum_{i=1}^B S_{\theta}(v_i, v'_i) - \beta \cdot \frac{2\alpha}{B} \sum_{i=1}^B \ln \left(\sum_{j \neq i} \exp \frac{S_{\theta}(v_i, v_j)}{\alpha} + \sum_j \exp \frac{S_{\theta}(v_i, v'_j)}{\alpha} \right)$$

$$S_{\theta}(u_1, u_2) \triangleq \frac{\langle \phi(u_1), \psi(u_2) \rangle}{\|\phi(u_1)\|_2 \cdot \|\psi(u_2)\|_2}.$$

$$\text{BYOL 손실함수 : } L_{\theta, \xi} = \|q_{\theta}(z_{\theta}) - z'_{\xi}\|^2 = 2 - 2 \cdot \frac{\langle q_{\theta}(z_{\theta}), z'_{\xi} \rangle}{\|q_{\theta}(z_{\theta})\| \|z'_{\xi}\|}$$

- BYOL의 손실함수는 온라인 예측과 타깃 투영의 L2-정규화 후 MSE 최소화이므로 정규화된 벡터의 MSE 최소화 == 코사인 유사도 최대화 이므로 SimCLR의 positive attraction과 같다
- $\beta = 1$, Predictor X, target Network X -> SimCLR에 해당
- $\beta = 0$, Predictor O, target Network O -> BYOL에 해당

5. Building intuitions with ablations

5.4 Ablation with Contrastive methods

- BYOL의 손실함수는 온라인 예측과 타겟 투영의 L2-정규화 후 MSE 최소화이므로 정규화된 벡터의 MSE
최소화 = 코사인 유사도 최대화 이므로 SimCLR의 positive attraction과 같다
- $\beta = 1$, Predictor X, target Network X -> SimCLR에 해당
- $\beta = 0$, Predictor O, target Network O -> BYOL에 해당

$$\ell(i, i') = -\log \frac{\exp(S(v_i, v'_i)/\tau)}{\sum_{j \neq i} \exp(S(v_i, v_j)/\tau) + \sum_j \exp(S(v_i, v'_j)/\tau)}$$

$$\text{InfoNCE}_{\theta}^{\alpha, \beta} = \frac{2}{B} \sum_{i=1}^B S(v_i, v'_i) - \beta \cdot \frac{2\alpha}{B} \sum_{i=1}^B \log \left(\sum_{j \neq i} e^{S(v_i, v_j)/\alpha} + \sum_j e^{S(v_i, v'_j)/\alpha} \right)$$

$$\ell(i, i') = -\frac{1}{\tau} S(v_i, v'_i) + \log \left(\sum_{j \neq i} e^{S(v_i, v_j)/\tau} + \sum_j e^{S(v_i, v'_j)/\tau} \right).$$

$$\text{InfoNCE}_{\theta}^{\tau, 1} = \frac{2}{B} \sum_i S(v_i, v'_i) - \frac{2\tau}{B} \sum_i \log(\dots) = -\tau \mathcal{L}_{\text{NT-Xent}}$$


양방향 합 적용

$$\mathcal{L}_{\text{NT-Xent}} = -\frac{2}{B\tau} \sum_{i=1}^B S(v_i, v'_i) + \frac{2}{B} \sum_{i=1}^B \log \left(\sum_{j \neq i} e^{S(v_i, v_j)/\tau} + \sum_j e^{S(v_i, v'_j)/\tau} \right)$$

- 사전학습 과정은 특징 추출이 주요한 목표이므로 라벨링된 데이터를 통한 특징 추출이 아닌 새로운 방식의 pretext task 도입
- 동일한 이미지에서 두개의 증강 뷰를 사용하여 하나의 뷰에서 다른 뷰 표현을 예측하도록 학습
- 각각의 뷰에 따른 두 개의 네트워크, 온라인 네트워크와 타겟 네트워크를 도입, 온라인 네트워크는 예측기 모듈 포함 및 손실함수를 통한 BP, 타겟 네트워크는 EMA를 통한 가중치 조정
- BYOL은 negative sample 이나 대규모 배치 크기, 메모리 बैं크 없이도 강력한 자기지도 학습 성능으로 뛰어난 Upstream task 수행 가능
- 향후 이미지 분석 뿐만 아니라 다른 모달리티(오디오, 비디오)나 멀티 모달로의 확장 가능성

Bootstrap Latent Representations for Multi-modal Recommendation

WWW '23: Proceedings of the ACM Web Conference 2023



the hidden ID embedding H^{l+1} at layer $(l + 1)$

* ID 임베딩 = 각 사용자/아이템 ID에 대응하는 학습 가능한

$$H^{l+1} = \sigma(\hat{A}H^lW^l)$$

감사합니다

