

Learning Transferable Visual Models From Natural Language Supervision

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever

Presented in PMLR (2021)

HEART Lab 석사 과정생 하린, 학부 인턴 강성찬, 유건

2025. 8. 26

Contents



- 01.** Introduction and Motivating Work
- 02.** Approach
- 03.** Experiments
- 04.** Comparison to Human Performance
- 05.** Data Overlap Analysis
- 06.** Limitations
- 07.** Broader Impacts
- 08.** Conclusion


1. Introduction and Motivating Work

- BERT, OpenAI GPT 등 기존 연구들은 대규모 텍스트 데이터를 모아 사전학습 후 미세조정(pre-training and fine-tuning)하는 방식으로 자연어처리 분야에서 매우 뛰어난 성과를 얻었음
 - Masked Language Modeling을 통한 학습(라벨 없이 웹규모로 사전학습)
 - "text-to-text" 방식(태스크마다 다른 토큰 X)을 통해 모델이 대규모의 데이터를 이용해 학습할 수 있도록 함
- > GPT-3는 라벨링된 데이터셋 없이도 다양한 태스크에서 좋은 성능을 내는 모델이 되었음
- 자연어처리 분야에서는 적은 양의 라벨이 붙은 고품질 데이터셋보다, 많은 양의 웹 상에서 수집된 라벨이 없는 데이터가 더 학습에 용이하게 사용됨
- 컴퓨터 비전과 같은 분야에서는 적은 양의 라벨이 붙은 고품질 데이터셋을 이용해 계속 학습

**"자연어처리 분야처럼 웹 상에서 수집된 테스트로부터 사전 학습을 하는 방식을
컴퓨터 비전 분야에 적용해 혁신을 가져올 수 있을까?"**

1. Introduction and Motivating Work

- text로부터 image representation을 학습시키는 방법론이 있었으며 선행연구를 보면 가능!
 - 최근의 방식은 transformer-based의 language modeling, masked language modeling 및 contrastive objectives를 이용
- 기존의 text로부터 image representation을 학습시키는 모델의 성능 뛰어나지 않음
 - Visual N-Grams
ImageNet의 정확도가 11.5%밖에 되지 않았는데, 가장 좋은 성능(SOTA)은 88.4%
- Weak supervision에서 사용은 성과를 보임
(정확한 골드 라벨 대신, 해시태그나 캡션 많은 라벨(노이즈 라벨)처럼 덜 정밀한 정보로 학습)
 - 하지만 자연어 처리를 이용한 image representation 모델과는 scale 차이가 있음



VIRTEX, ICMLM, ConVIRT -> 20만개

‘4억개의 [이미지, 텍스트] 페어, 이를 ConVIRT의 간단한 버전을 이용해 학습’
Contrastive Language-Image Pre-training, 줄여서 CLIP

2. Approach


2.1 Natural Language Supervision

- Scale을 키우기 쉽다

(이전의 방법론에서는 *scale*을 키우기 위해서는 일일이 라벨링 된 데이터를 많이
> 수작업 라벨링을 안 하고, 웹에 이미 붙어 있는 "이미지-텍스트 쌍"을 그대로)

- 단순히 표현을 학습하는 것이 아니라 해당 표현을 언어에 연결하여 유연한 Zero-shot Transfer를 가능하게 한다

- 학습 때 본 적 없는 클래스.과 "새로운 클래스"로 적용하여 맞춤



2.2 Creating a Sufficiently Large Dataset

- 이때까지의 연구들은 주로 세 가지 데이터셋을 사용했다
 - MS-COCO  양질의 라벨링된 데이터셋이지만 그 양이 각각 대략 10만개정도 많지 않다
 - Visual Genome  1억개의 사진으로 양이 많지만 비교적 양질의 데이터가 아니다 (메타데이터 부족)
 - YFCC100M
- 다른 컴퓨터비전 분야에서 사용하는 데이터셋의 크기는 훨씬 큰데, 35억개의 인스타그램 사진을 이용해 학습


CLIP에서는 **WIT**(WebImageText)라고 명명하는 새로운 데이터셋을 만들
이는 인터넷의 다양한 사이트에서 가져온 4억 개의 (image, text) 쌍으로 구성되어 있음

- 데이터의 다양성을 얻기 위해, 50만 개의 텍스트 쿼리를 이용했으며, 하나의 쿼리에서 2만 개가 넘는 (image, text) 페어를 갖지 않도록 함

2. Approach

2.3 Selecting an Efficient Pre-Training Method


- 기존의 연구에서는 ImageNet 데이터에서 단지 **1000개 class 분류**를 위해 매우 많은 GPU 메모리를 사용
- 초기 접근법 : VirTex와 유사하게 **이미지는 CNN으로, 텍스트는 transformer**를 이용해 학습시키고 각각 이미지에 대해 이미지의 설명 텍스트(caption)를 예측하는 태스크를 수행
- 기존의 방식에서는 텍스트 문장을 예측할 때 그 문장 그대로, 즉 단어의 순서까지 정확 맞추는 태스크로 학습
->본 연구에서는 순서는 고려하지 않고 예측할 수 있도록 **bag-of-words encoding**을 사용해 **contrastive learning**을 했다



2. Approach

2.3 Selecting an Efficient Pre-Training Method

(1) Contrastive pre-training



- A. 기본적으로 배치 단위로 학습이 이뤄지는데, 예를 들어 배치 사이즈가 N 이라고 하면 N 개의 (image, text) 페어
- B. 텍스트는 Text Encoder를 이용해 벡터 값으로 표현되게 되고, 이미지는 Image Encoder를 이용해 벡터 값으로 표현
- C. N 개의 텍스트 벡터와 N 개의 이미지 벡터 사이의 코사인 유사도를 구함
- D. 총 $N \times N = N^2$ 개의 값이 나오는데
 - N 개는 실제 맞는 페어(positive pair)에서 나온 값이고
 - $N^2 - N$ 개는 다른 페어(Negative pair)에서 나온 값
- E. Cross Entropy loss 값을 계산해 최적화
 - ➔ Pos 코사인 유사도 최대
 - ➔ Neg 코사인 유사도 최소

2. Approach

2.3 Selecting an Efficient Pre-Training Method

```
# image_encoder - ResNet or Vision Transformer
# text_encoder  - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l]       - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t            - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]





# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss   = (loss_i + loss_t)/2
```

2.4 Choosing and Scaling a Model

(1) Contrastive pre-training



- Image Encoder로 두 가지 다른 모델 이용
 - ResNet-50** (합성곱 + 잔차블록 + 글로벌 풀링 -> 벡터)
 - Vision Transformer(ViT)** ([CLS] 토큰이 이미지 요약)

Global pooling 또는 [CLS] 토큰을 뽑아 표현을 만듦

- Text Encoder로는 **Transformer**를 이용

토큰나이저 (BPE 등) + 위치 임베딩 ~> 트랜스포머 블록

이전의 컴퓨터비전 연구는 모델의 너비와 깊이 중 하나만 이용해 모델을 확장

-> ResNet Image Encoder의 경우 너비, 깊이, 해상도 모두 확장

Text Encoder의 경우 Resnet 너비에 맞춰주긴 했으나, 추가적으로 깊이를 증가시키지는 않았는데, CLIP의 성능이 Text Encoder의 크기에 덜 민감하다는 것을 알게 되었기 때문

2.5 Training

모델 라인업

- ResNet 5종: RN50, RN101, RN50x4, RN50x16, RN50x64
- ViT 3종: ViT-B/32, ViT-B/16, ViT-L/14 (총 8개 모델)

학습 설정(공통)



- 총 32 에포크로 학습했고, 옵티마이저는 Adam(가중치 감쇠는 분리: AdamW) 를 사용
- 학습률은 코사인 스케줄로 점진적으로 감소
- 하이퍼파라미터는 RN50(1 epoch)에서 그리드 서치·랜덤 서치·수동 튜닝으로 설정 → 휴리스틱하게 확장 적용
- 온도 파라미터 τ 는 0.07로 초기화했고, 학습 안정성을 위해 logits가 100을 넘지 않도록 클리핑
- 초대형 미니배치 32,768

3. Experiments

3.1 Zero-shot Transfer

1. Motivation

- 기존의 Zero-shot은 학습되지 않은 객체 카테고리에 대한 일반화 연구를 의미
- CLIP에서는 학습되지 않은 카테고리에 대한 일반화를 넘어서 **Unseen dataset으로의 일반화**로 정의됨
- 새로운 데이터 분포에서의 작업 학습(task-learning) 능력을 측정하는 지표




3.1 Zero-shot Transfer

2. Using CLIP for Zero-Shot Transfer


- CLIP에선 각 클래스 이름으로 텍스트 프롬프트 집합을 만들고 이미지와 텍스트를 각각의 인코더로 임베딩
- Zero-Shot 분류기를 위해 임베딩된 두 특징 벡터를 L2 정규화한 뒤 코사인 유사도를 구함
- 또한 유사도를 온도 τ 로 스케일링, softmax로 정규화하여 확률 p 얻음
- 인코더 후 네트워크는 L2 정규화 된 입력값, 가중치로 이루어진 다항 로지스틱 회귀($bias = 0$)과 동일함 여기서 가중치는 텍스트 인코더로부터 나온 특징벡터

※온도 τ 스케일링은 특징공간 위 데이터의 확률 sharpness를 의미함,
 $\tau \uparrow$, 가장 유사한 최유사 후보에 집중 / $\tau \downarrow$, 여러 유사후보에 고르게 분포

(2) Create dataset classifier from label text



(3) Use for zero-shot prediction



$$\cos(v_I, v_{Tj}) = \frac{v_I \cdot v_{Tj}}{\|v_I\| \|v_{Tj}\|} = W(V_T \text{를 의미}) \cdot X^T(V_i \text{를 의미})$$

3.1 Zero-shot Transfer

3. Initial Comparison To Visual N-Grams

- **CLIP**은 WebImageText(400M 이미지-텍스트 쌍, 웹 수집)으로 대조학습 사전학습된 제로샷 모델
- **Visual N-Grams**는 YFCC(100M 이미지-댓글 쌍)으로 웹에서 뽑은 문구 예측기를 CNN으로 학습해, 클래스명 = 문구로 간주해 제로샷 분류를 하는 베이스라인 모델
- CLIP이 10배 더 큰 데이터셋, 한 예측 당 100배 더 많은 연산이 드는 비전 모델 사용, 학습 연산 1000배 이상, 인코더는 transfer model 사용

Visual N-Grams vs CLIP

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	98.4	76.2	58.5

Table 1. Comparing CLIP to prior zero-shot transfer image classification results. CLIP improves performance on all three datasets by a large amount. This improvement reflects many differences in the 4 years since the development of Visual N-Grams (Li et al., 2017).

3. Experiments

3.1 Zero-shot Transfer

4. Prompt Engineering And Ensembling

- 텍스트 프롬프트를 통해 동의어 클래스, 다중 클래스 예측 향상
- EX) ImageNet의 한 사진 : 공사장 크레인과 두루미 클래스, Oxford-Pet : {boxer} 클래스 = 권투선수로 해석 가능
- Pre-training 분포와 격차를 줄이기 위해 텍스트 프롬프트를 **"A photo of a {label}"** 사용 시 격차 줄어듦
- 여러 프롬프트로 만든 텍스트 임베딩들을 평균해 Label 별로 하나의 가중치 벡터를 만들어서 제로샷 분류기 하나를 구성하여 성능을 높였음
- 따라서 클래스 이름 그대로 텍스트 인코더 입력(파란 선)에 비해 평균 약 5% Acc 향상




Figure 4. Prompt engineering and ensembling improve zero-shot performance. Compared to the baseline of using contextless class names, prompt engineering and ensembling boost zero-shot classification performance by almost 5 points on average across 36 datasets. This improvement is similar to the gain from using 4 times more compute with the baseline zero-shot method but is “free” when amortized over many predictions.

3. Experiments

3.1 Zero-shot Transfer

5. Analysis of Zero-Shot CLIP Performance

- **Linear Probe on ResNet50** : ImageNet-1K 사전학습 backbone & 로지스틱 회귀 지도 학습 선형 분류기
- **Zero-Shot CLIP**은 27개 데이터셋 부문에서 16개가 베이스라인 모델보다 성능 앞섬




Figure 5. Zero-shot CLIP is competitive with a fully supervised baseline. Across a 27 dataset eval suite, a zero-shot CLIP classifier outperforms a fully supervised linear classifier fitted on ResNet-50 features on 16 datasets, including ImageNet.

3.1 Zero-shot Transfer

5. Analysis of Zero-Shot CLIP Performance

- X축 : 클래스당 라벨된 학습 샘플 수, y축은 위 페이지에 나온 27개 데이터셋에 대한 평균 Acc
- **Linear Probe CLIP** : CLIP 이미지 특징 고정. 라벨 별 소수의 데이터로 로지스틱 회귀 전이학습
- **BiT-M** : BiT-M ResNet-152*2를 ImageNet-21K로 지도 사전학습. 해당 특징 위에 소수의 데이터로 로지스틱 회귀
- **SimCLRv2** : ImageNet 기반 contrastive learning 사전학습 특징 사용, 소수의 데이터로 로지스틱 회귀 사용

※ BiT-M : ResNet-v2 계열을 ImageNet-21K로 사전학습한 Backbone 모델




Figure 6. Zero-shot CLIP outperforms few-shot linear probes. Zero-shot CLIP matches the average performance of a 4-shot linear classifier trained on the same feature space and nearly matches the best results of a 16-shot linear classifier across publicly available models. For both BiT-M and SimCLRv2, the best performing model is highlighted. Light gray lines are other models in the eval suite. The 20 datasets with at least 16 examples per class were used in this analysis.

3. Experiments

3.1 Zero-shot Transfer

5. Analysis of Zero-Shot CLIP Performance

- 각각의 데이터셋마다 Zero-Shot CLIP의 정확도를 달성하기 위해 Linear Probe CLIP에서 필요한 **지도 학습 데이터 샘플의 개수**
- Linear Probe CLIP은 CLIP으로 사전학습 되어 있으며 transfer learning에서 각각의 데이터셋을 표에 나온 표본 개수대로 학습 하였을 때 Zero-shot CLIP의 정확도 달성함




Figure 7. The data efficiency of zero-shot transfer varies widely. Calculating the number of labeled examples per class a linear classifier on the same CLIP feature space requires to match the performance of the zero-shot classifier contextualizes the effectiveness of zero-shot transfer. Values are estimated based on log-linear interpolation of 1, 2, 4, 8, 16-shot and fully supervised results. Performance varies widely from still underperforming a one-shot classifier on two datasets to matching an estimated 184 labeled examples per class.

3.1 Zero-shot Transfer

5. Analysis of Zero-Shot CLIP Performance

- Zero-Shot CLIP의 이미지 인코더가 figure 9.와 같을 때 **평균 Zero-Shot 에러율**을 의미함
- X축은 Log Scale을 갖고 있어 모델의 연산량이 지수적으로 늘어날 때 에러가 선형적으로 감소함







Figure 9. Zero-shot CLIP performance scales smoothly as a function of model compute. Across 39 evals on 36 different datasets, average zero-shot error is well modeled by a log-log linear trend across a 44x range of compute spanning 5 different CLIP models. Lightly shaded lines are performance on individual evals, showing that performance is much more varied despite the smooth overall trend.

3. Experiments

3.2 Representation Learning

- CLIP을 Zero-Shot 모델에 적용하지 않고 **transfer learning** 하였을 때의 다른 모델들과 정확도 비교
- ResNet-50/101을 transfer learning에 사용했을 때 BiT-M이나 EfficientNet에 미치지 못함
그러나 모델 구조가 커질수록 CLIP-ResNet이 우세
- CLIP-ViT는 CLIP-ResNet 대비 3배 연산 효율이 높으면서 다른 모든 계열에서 정확도 앞섬



3. Experiments

3.2 Representation Learning

- 27개의 데이터셋에서 **Linear Probe CLIP**(적은 데이터셋으로 지도학습)과 **EfficientNet L2 NS**와의 정확도 차이
- ImageNet의 단일 라벨 감독은 클래스 내 세부 구분을 축소시킬 위험이 있어 미세구분 전이에서 손실이 날 수 있음

※ 같은 '대교'라는 클래스를 가진 이미지여도 사진 내의 세부 내역, 맥락이 다름

- CLIP은 텍스트 인코더에 의해 **텍스트, 장면, 행동 개념에 넓게 일반화**





Figure 11. CLIP's features outperform the features of the best ImageNet model on a wide variety of datasets. Fitting a linear classifier on CLIP's features outperforms using the Noisy Student EfficientNet-L2 on 21 out of 27 datasets.

3. Experiments

3.3 Robustness to Natural Distribution Shift (데이터셋의 자연 분포 이동)

OOD(Out Of Distribution), Effective robustness

- **OOD 정확도** : 훈련 데이터셋에 대하여 분포가 바뀐 테스트 데이터셋에서의 정확도
- **Effective robustness** : 같은 ID(in Distribution) 데이터 학습 모델에 대해 OOD 데이터 정확도를 공정하게 평가하기 위한 차이 값
- Reference accuracy : ID 정확도 (보통 ImageNet에서의 top-1 정확도)
- Shifted accuracy : ID 데이터에 대해 분포가 다른 7개의 데이터셋들의 평균 정확도



3. Experiments

3.3 Robustness to Natural Distribution Shift

- X축 : ImageNet 데이터셋에서의 정확도
- Y축 : 다른 12개 데이터셋 테스트의 평균 정확도
- 각 모델 계열들의 고정 특징 + 로지스틱 회귀 구조의 테스트 결과
- 동일한 ID Acc 상에서 OOD Acc 측정 시 CLIP-ViT, CLIP-ResNet이 가장 높은 Acc, task shift에 더 잘 전이




Figure 12. CLIP's features are more robust to task shift when compared to models pre-trained on ImageNet. For both dataset splits, the transfer scores of linear probes trained on the representations of CLIP models are higher than other models with similar ImageNet performance. This suggests that the representations of models trained on ImageNet are somewhat overfit to their task.

3. Experiments

3.3 Robustness to Natural Distribution Shift




Figure 13. Zero-shot CLIP is much more robust to distribution shift than standard ImageNet models. (Left) An ideal robust model (dashed line) performs equally well on the ImageNet distribution and on other natural image distributions. Zero-shot CLIP models shrink this “robustness gap” by up to 75%. Linear fits on logit transformed values are shown with bootstrap estimated 95% confidence intervals. (Right) Visualizing distribution shift for bananas, a class shared across 5 of the 7 natural distribution shift datasets. The performance of the best zero-shot CLIP model, ViT-L/14@336px, is compared with a model that has the same performance on the ImageNet validation set, ResNet-101.

- CLIP Zero-Shot이 Effective Robustness가 훨씬 크며 성능 격차를 최대 75% 축소한다는 의미
- ResNet101 ImageNet 사전학습 모델은 ImageNetV2, ImageNet-R, ObjectNet 등의 데이터셋에서 Zero-Shot CLIP 모델보다 정확도가 현저히 떨어짐


4. Comparison to Human Performance

• Human vs CLIP

- Oxford IIT Pets dataset을 사용하여 5명의 다른 사람에게 3,669개의 이미지를 주고 37종류의 개/고양이 class를 분류하도록 함(I don't know 도 선택 가능)
- Zero-shot: 인터넷 검색 없이, 아무런 예시도 보지 못한 채 이미지 labeling
- One-shot, Two-shot: 각각 1개, 2개의 예시를 본 다음 이미지 labeling

	Accuracy	Majority Vote on Full Dataset	Accuracy on Guesses	Majority Vote Accuracy on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	93.5	93.5	93.5	93.5
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

- ➔ 인간은 Zero-shot에서 One-shot으로 갈 때는 유의미한 성능 향상이 있었지만, One-shot에서 Two-shot으로 갈 때는 성능 변화가 미미함
- ➔ 이는 인간이 "자신이 모르는 것을 알고" 있다는 것을 의미함 (예시가 더 많아진다고 해서 더 알게 되지는 않음)
- ➔ 이와 달리 CLIP은 shot을 늘려갈수록 성능이 좋아지므로, 알고리즘 개선이 이루어질 여지가 있음





5. Data Overlap Analysis

- 대규모 데이터셋을 통해 사전학습할 경우, 평가 데이터와 사전학습 데이터가 overlap 될 수 있음
- 이는 일종의 cheating이 될 수 있기 때문에 평가 결과가 부정확하고, 모델의 정확한 성능을 측정할 수 없게 됨
- 이를 방지하는 방법은 데이터셋에서 모든 중복 데이터를 제거하는 것이지만,

CLIP에서 데이터가 얼마나 겹치는지, 그리고 이것이 얼마나 성능에 영향을 주는지를 평가하여 정확한 성능을 측정하고자 함

[Data Overlap 분석 방법]

1. 각 데이터셋마다 얼마나 겹치는지 duplicate detector를 만들어 사용한다.
그리고 가장 가까운 이웃을 찾고 데이터셋마다 recall을 최대화하면서 높은 precision을 유지하도록 임계값(threshold)을 설정하고, 이 임계값을 사용해 2개의 하위 집합(Overlap, Clean)을 만든다.
 - Overlap: 임계값을 초과하여 train example과 유사도가 높은 example
 - Clean: 임계값 이하의 example
 - All: 수정하지 않은 전체 데이터셋
2. 위 3개의 split에 대해 zero-shot CLIP 성능을 측정하고, *All - Clean* 을 주요 측정 지표로 사용한다.
이 값이 양의 값이라면, 측정된 정확도 중 얼마만큼이나 오염된 데이터에 의해 부풀려졌는지(overfitting) 확인할 수 있다.
3. Overlap된 정도가 낮은 경우 이항 검정을 수행하고, Overlap 부분집합에 대해 one-tailed(greater) p-value 값을 계산한다.



→(왼쪽) Overlap vs Clean

35개 중 5개의 데이터셋만이 99.5% 신뢰구간을 벗어남
그러나 2개의 데이터셋에서는 overlap이 발생했음에도 성능이 더 낮음

→(오른쪽) Overlap이 정확도에 준 영향

Detector로 탐지한 overlapping example의 비율이 한 자리수이기 때문에 overlap에 의한 정확도 향상이 크지 않음
다만 보정하여 새로 계산한 결과, 6개의 데이터셋이 유의미한 차이가 있음

→ 일부 데이터셋에서만 data overlap으로 인해 정확도가 부풀려짐

- CLIP은 ResNet-50에 비교해서 zero-shot 성능이 더 좋긴 하나, 현재 SOTA에 비해 부족함
- Zero-shot CLIP이 현재 SOTA 성능에 도달하기 위해서는 계산량이 1000배 이상 증가해야 하지만, 현실적으로 불가능하기 때문에 연산 효율성 증대를 위한 추가 연구가 필요함
- Zero-shot CLIP은 특정 task에서 여전히 좋지 않은 성능을 보임
- 특히, Task-specific 모델과 비교하여 fine-grained classification(자동차 모델, 꽃 종류 등 세분화된 분류)에 취약함
- 사진에서 가장 가까운 자동차까지의 거리를 구하는 것과 같이, CLIP이 사전학습 단계에서 학습했을 리 없는 새로운 task의 정답률은 거의 찍는 수준임
- CLIP은 고품질의 OCR representation을 학습하지만, MNIST에서 88%의 정확도밖에 달성하지 못함
- 이는 매우 단순한 logistic regression 모델보다 낮은 이 성능이며, 사전학습 데이터셋에 MNIST의 손글씨 이미지와 유사한 example이 거의 없기 때문일 것으로 보임
- 즉, CLIP은 일반적인 딥러닝 모델이 취약한 일반화(generalization)라는 근본적인 문제를 거의 해결하지 못함
- 딥러닝의 데이터 활용률이 매우 낮은 것도 별로 개선하지 못했는데, 4억 개의 이미지를 1초에 하나씩 32 epoch을 수행하면 405년이 걸림
- 즉, CLIP은 적은 데이터로 잘 배우는 모델이라기 보다 큰 데이터를 효과적으로 쓰는 방법에 가까움
- 인터넷에서 그냥 수집한 데이터로 CLIP을 학습시켰기 때문에 CLIP은 사람이 가지고 있는 여러 사회적 편견들도 똑같이 학습하게 되어 윤리 문제가 발생함

• 7.1. Bias (편견)

- 사회적 편견은 데이터셋 내에 그대로 녹아들어가 있고, 이를 통해 학습하는 모델 역시 이를 그대로 학습할 수 있음
- 특정 집단이 비하적 라벨(비인간·범죄 관련)로 불균형적으로 분류되는지 점검하기 위해,
- FairFace 데이터 세트에서 10,000개의 이미지를 분류해야 하는 실험을 수행함

[실험 방법]

- FairFace의 기존 class에 새로운 class name을 추가함
 - 비인간: '동물', '고릴라', '침팬지', '오랑우탄'
 - 범죄: '도둑', '범죄자', '수상한 사람'

[결과]

- 전체 이미지의 4.9% 정도는 분명 사람의 이미지임에도 위에서 추가한 비인간 class로 잘못 분류됨
- 이 중 '흑인' 이미지가 가장 높은 오분류율(약 14%)을 보였고, 다른 모든 인종은 8% 미만의 오분류율을 보임
- 0~20세의 사람들이 이 범주로 분류되는 비율이 14%로 가장 높음
- 남성 이미지의 16.5%가 범죄 관련 클래스로 잘못 분류된 반면, 여성 이미지는 9.8%로 나타남
- 0~20세의 사람들(약 18%)이 다른 연령대의 사람들 이미지(20~60세: 약 12%, 70세 이상: 0%)에 비해 범죄 관련 클래스에 속할 가능성이 더 높은 것으로 나타남

- **7.1. Bias (편견)**
- 비인간 오분류: 전체 4.9%(Black 약 14%)
- 범죄 관련: 남성 16.5% vs 여성 9.8%, 0-20세에서 더 높음(18%)
- 그러나 child 추가 후 0-20세의 비하 라벨 분류가 크게 감소함

Category Label Set	0-2	3-9	10-19	20-29	30-39	40-49	50-59	60-69	over 70
Default Label Set	30.3	35.0	29.5	16.3	13.9	18.5	19.1	16.2	10.4
Default Label Set + 'child' category	2.3	4.3	14.7	15.0	13.4	18.2	18.6	15.5	9.4

Table 7. Percent of images classified into crime-related and non-human categories by FairFace Age category, showing comparison between results obtained using a default label set and a label set to which the label 'child' has been added. The default label set included 7 FairFace race categories each for men and women (for a total of 14), 3 crime-related categories and 4 non-human categories.

➔ **라벨셋(클래스) 설계:** 포함하는 클래스와 서술어 선택에 따라 결과가 크게 바뀜

7. Broader Impacts

• 7.1. Bias (편견)

- 이외에도 국회의원 관련 데이터셋으로 평가했을 때,
- 남성은 prisoner, mobster(제소자, 조직폭력배), 여성은 nanny, housekeeper(유모, 가정부)와 연관이 깊다고 나옴
- 또한 여성은 갈색 머리, 금발과 같은 외모와 연관이 잘 지어지는 반면, 남성은 임원, 의사와 같은 높은 직위의 직업과 더 잘 짝지어짐

• 임계값 4.0%

- 남녀 공통으로 확률이 가장 높은 상위 라벨이 "lawmaker", "legislator", "congressman" 등으로 보수적(엄선된) 라벨만 주로 남음.
- 여성 이미지에 대해 'military person', 'executive' 같은 직업 라벨이 사용되지 않음
- 정밀도(precision) ↑, 재현율(recall) ↓

※ 임계값: 라벨을 선택할 최소 확률
※ 정밀도: 모델이 True라고 분류한 것 중에서 실제 True인 것의 비율
※ 재현율: 실제 True인 것 중에서 모델이 True라고 예측한 것의 비율

• 임계값 0.5%

- 여성에 'nanny'/'housekeeper', 남성에 'prisoner'/'mobster' 같은 성 역할·범죄 연상 라벨이 등장
- 남성을 설명하는 레이블이 '정장', '넥타이' 및 '넥타이'와 같은 외모 지향적인 단어로 이동함
- 여성의 이미지를 설명하는 데 사용되지 않았던 '군인' 및 '임원'과 같은 많은 직업 지향적인 단어가 남성과 여성 모두에게 사용됨 (반대는 성립X)
- 재현율(recall) ↑, 정밀도(precision) ↓

➔ 임계값: 임계값 선택만으로 출력 라벨 분포와 편향 양상이 크게 달라짐

7. Broader Impacts

- 7.2. Surveillance (감시)

- CCTV 카메라 이미지 분류

- '빈 주차장/학교 캠퍼스' 등 주요 주제를 맞추는 task
 - Top-1 정확도: 91.8%
- 구석의 사람 존재 등 작은 특징의 존재/부재를 맞추는 task (fine-grained task)
 - 정확도: 51.1%, '비슷한 오답'을 40.7% 선택 ('하얀 차가 있는 주차장' vs '빨간 차가 있는 주차장')
 - 세밀 탐지에서는 제로샷 모델 성능이 무작위에 가깝게 낮음

- 유명한 식별

Model	100 Classes	1k Classes	2k Classes
CLIP L/14	59.2	43.3	42.2
CLIP RN50x64	56.4	39.5	38.4
CLIP RN50x16	52.7	37.4	36.3
CLIP RN50x4	52.8	38.1	37.3

→ CLIP L/14 = ViT-L/14
Large Vision Transformer

→ CLIP RN50x64 / RN50x16 / RN50x4
ResNet-50을 스케일업한 CNN

- task-specific한 학습을 하지 않았기 때문에 다른 유명한 모델(ex. Celebrity Recognition)보다 성능이 떨어짐
- CLIP은 특정 감시 작업에는 효용이 떨어지기는 하지만 맞춤형 감시 작업의 문턱을 낮출 수도 있음

→ CLIP은 제로샷 능력 덕분에 데이터가 적은 과제에는 이점이 있지만, 얼굴인식 등 수요가 큰 감시 과제에는 대규모 데이터·고성능 감독 모델이 이미 존재하기에 비교 매력도가 낮음

→ 그럼에도 훈련 데이터가 필요 없다는 점은 맞춤형 감시 용례를 가능케 할 수 있고, 개발 난이도도 낮출 수 있음

- **7.3. Future Work (향후 연구)**

- 다음을 통해 모델이 유용하게 사용될 가능성을 높일 수 있음:
 - 연구 초기에 모델의 잠재적인 downstream task를 생각하고, 응용에 대해 생각해 본다.
 - 정책 입안자의 개입이 필요할 수 있는 상당한 민감도를 가지는 작업을 표면화한다.
 - 모델의 편향을 더 잘 특성화하여, 다른 연구자들의 관심 영역과 개입 영역에 대해 경고한다.
 - 추후 연구를 위해 잠재적인 실패 모드와 영역을 식별한다.

- 자연어처리(NLP) 분야에서의 크게 성공한 task-agnostic web-scale 사전학습 방식을 vision에 적용함
- CLIP은 사전학습 중 다양한 작업을 수행하는 방법을 학습하며, 자연어 프롬프트를 통해 여러 기존 데이터셋에 대해 zero-shot 전이가 가능함
- CLIP은 충분한 scale을 갖추면 task-specific supervised model과도 경쟁할 수 있는 모델이며 개선할 부분도 많음

감사합니다



Dataset	Classes	Train size	Test size	Evaluation metric
Food-101	102	75,750	25,250	accuracy
CIFAR-10	10	50,000	10,000	accuracy
CIFAR-100	100	50,000	10,000	accuracy
Birdsnap	500	42,283	2,149	accuracy
SUN397	397	19,850	19,850	accuracy
Stanford Cars	196	8,144	8,041	accuracy
FGVC Aircraft	100	6,667	3,333	mean per class
Pascal VOC 2007 Classification	20	5,011	4,952	11-point mAP
Describable Textures	47	3,760	1,880	accuracy
Oxford-IIIT Pets	37	3,680	3,669	mean per class
Caltech-101	102	3,060	6,085	mean-per-class
Oxford Flowers 102	102	2,040	6,149	mean per class
MNIST	10	60,000	10,000	accuracy
Facial Emotion Recognition 2013	8	32,140	3,574	accuracy
STL-10	10	1000	8000	accuracy
EuroSAT	10	10,000	5,000	accuracy
RESISC45	45	3,150	25,200	accuracy
GTSRB	43	26,640	12,630	accuracy
KITTI	4	6,770	711	accuracy
Country211	211	43,200	21,100	accuracy
PatchCamelyon	2	294,912	32,768	accuracy
UCF101	101	9,537	1,794	accuracy
Kinetics700	700	494,801	31,669	mean(top1, top5)
CLEVR Counts	8	2,000	500	accuracy
Hateful Memes	2	8,500	500	ROC AUC
Rendered SST2	2	7,792	1,821	accuracy
ImageNet	1000	1,281,167	50,000	accuracy